

Optimización de costos

Matriz de decisión de modelos de IA por tipo de tarea

1. Criterio general

No todas las tareas de un sistema de IA necesitan el mismo modelo. Un modelo grande y caro aporta poco valor extra en una tarea simple y repetitiva, mientras que un modelo chico puede quedarse corto en una tarea que requiere comprensión profunda de contexto. La matriz de abajo clasifica las tareas que puede tener este ecosistema (la implementada y las de una posible extensión futura) y justifica qué modelo conviene en cada caso.

2. Matriz de decisión

Tarea	Modelo elegido	Por qué	Alternativas descartadas
Clasificar el mensaje entrante (tipo, prioridad, resumen) — IMPLEMENTADA	Gemini 3.5 Flash-Lite (free tier)	Tarea simple y estructurada, de alto volumen. No necesita razonamiento profundo, solo categorizar texto corto.	GPT-4o-mini: similar capacidad pero de pago. Claude Sonnet: sobra capacidad para esto, costaría ~20x más.
Resumir el historial completo de un cliente para el vendedor — EXTENSIÓN FUTURA	Claude Sonnet	Lectura densa: requiere entender matices, tono e historial largo con contexto, no solo extraer datos sueltos.	Gemini/GPT-mini: más baratos pero con más riesgo de perder matices en textos largos.
Generar la respuesta final al cliente (una vez aprobada) — EXTENSIÓN	Gemini 3.5 Flash-Lite	Mensaje corto basado en una plantilla ya aprobada por un humano, no requiere creatividad ni razonamiento.	Claude/GPT: calidad de escritura similar para un mensaje tan corto, pero más caro sin necesidad.
Reporte semanal agregado de todos los tickets — EXTENSIÓN FUTURA	API de Batches (procesamiento asíncrono)	No es tiempo real: se puede procesar de noche. Las APIs de lotes cobran hasta 50% menos que el precio estándar.	Llamada en tiempo real: mismo resultado, pero sin el descuento por lote.

Nota: de las cuatro tareas, solo la primera está implementada en el flujo actual (nodo HTTP Request → Gemini). Las otras tres se documentan como parte del diseño de arquitectura pensado para escalar el sistema — mismo criterio de decisión, aplicado de antemano.

3. Cálculo estimado de costo (tarea implementada)

Estimación basada en el volumen real de referencia del negocio (iPanel, ~50 clientes activos), asumiendo un promedio de 2 mensajes por cliente por mes que pasan por el nodo de clasificación.

Variable	Valor estimado
Clientes activos por mes	50
Mensajes clasificados por cliente/mes	2
Llamadas a la IA por mes	100
Tokens de entrada por llamada (prompt + mensaje del cliente)	~150 tokens
Tokens de salida por llamada (JSON de respuesta)	~50 tokens
Total de tokens por mes	15.000 entrada / 5.000 salida

Comparación de costo mensual según el modelo elegido:

Modelo	Precio aprox. (entrada / salida por 1M tokens)	Costo mensual estimado (100 llamadas)
Gemini 3.5 Flash-Lite (free tier)	\$0 dentro del límite gratuito	\$0.00
GPT-4o-mini (si se pagara)	\$0.15 / \$0.60	≈ \$0.005
Claude Sonnet (si se pagara)	\$3.00 / \$15.00	≈ \$0.12

Conclusión: para este volumen y este tipo de tarea, incluso si se pagara, la diferencia de costo entre modelos es mínima en términos absolutos — pero elegir el modelo correcto por tarea es igual de importante a mayor escala: si el volumen de mensajes creciera 100x (5.000 clientes), usar Claude Sonnet para la clasificación simple costaría aproximadamente **\$12/mes** sin ninguna mejora real de calidad, contra centavos con Gemini Flash-Lite o GPT-4o-mini. La decisión de usar el modelo más liviano para tareas simples es la que sostiene el ahorro a medida que el sistema escala — no un ajuste menor de tokens.